Data Challenge AssurPrime

Étude comparative de stratégies de modélisation en assurance incendie

Coletta Moutsiha

12 janvier 2026

Résumé

Ce rapport présente une comparaison de plusieurs approches de modélisation pour prédire une variable cible très déséquilibrée, avec beaucoup de valeurs nulles, dans un contexte de données tabulaires de grande dimension.

L'objectif est d'étudier l'impact de différentes façons de formuler le problème, allant d'une prédiction indirecte à partir de variables intermédiaires à une prédiction directe du coût annuel attendu. Les méthodes testées combinent des modèles d'arbres de décision et des modèles linéaires généralisés, et sont comparées à l'aide de la métrique imposée par le challenge.

1 Contexte et objectif

L'objectif du challenge est de prédire une variable cible positive et fortement asymétrique, notée `CHARGE`, associée à chaque observation du jeu de test.

Cette variable correspond à un coût cumulé observé sur une période donnée. Elle peut être exprimée comme le produit de trois composantes mesurées :

$$\texttt{CHARGE} = \texttt{FREQ} \times \texttt{CM} \times \texttt{ANNEE_ASSURANCE},$$

où :

- `FREQ` représente un taux d'occurrence moyen d'événements,
- `CM` correspond au coût moyen conditionnel par événement,
- `ANNEE_ASSURANCE` représente une durée d'exposition.

Cette relation fournit une factorisation naturelle de la variable cible et permet d'envisager différentes stratégies de modélisation : soit en prédisant directement la charge totale, soit en modélisant séparément ou conjointement ses composantes. Elle sert de point de départ à l'ensemble des approches comparées dans ce travail.

Définition de la RMSE. La métrique d'évaluation du challenge est la *Root Mean Squared Error* (RMSE), définie par :

$$\mathrm{RMSE} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}\left(\texttt{CHARGE}_i - \widehat{\texttt{CHARGE}}_i\right)^2}.$$

La RMSE accorde un poids plus important aux erreurs de grande amplitude, ce qui la rend particulièrement adaptée aux problèmes de régression impliquant des distributions asymétriques et des valeurs extrêmes. Elle encourage ainsi les modèles à limiter les erreurs importantes, au prix d'une sensibilité accrue aux outliers.

2 Description des données

Jeu de données	Lignes	Colonnes
`X_train`	383 610	374
`y_train`	383 610	5
`X_test`	95 852	374

Les données sont fortement hétérogènes :
— 94 variables numériques,
— plus de 270 variables catégorielles,
— de nombreuses valeurs manquantes.

3 Prétraitement des données

3.1 Gestion des valeurs manquantes

Les colonnes présentant plus de 99% de valeurs manquantes (`DEROG13`, `DEROG14`, `DEROG16`) sont supprimées. Les autres colonnes sont conservées afin de ne pas perdre d'information rare.

L'imputation est réalisée comme suit :
— variables numériques : imputation par la médiane,
— variables catégorielles : modalité `MISSING`.

3.2 Encodage des variables catégorielles

Un *Count Encoding* est utilisé : chaque modalité est remplacée par sa fréquence d'apparition dans l'échantillon d'apprentissage. Ce choix est motivé par :
— la forte cardinalité des variables,
— le volume important des données,
— la compatibilité avec les modèles d'arbres.

Listing 1 – Encodage des variables catégorielles par Count Encoding

```
encoder = CountEncoder(cols=cat_cols_model)
encoder.fit(X_train_model)

X_train_enc = encoder.transform(X_train_model)
X_test_enc  = encoder.transform(X_test_model)
```

4 Démarche méthodologique générale

La démarche suivie est progressive et guidée par l'observation empirique des performances des modèles :
— partir d'une modélisation de référence inspirée des approches classiques,
— analyser ses performances et ses limites sur un jeu de validation,
— proposer des alternatives plus robustes et mieux adaptées aux données.

Après le prétraitement, un découpage interne de type **80/20** est mis en place sur le jeu d'apprentissage :
— 80% des données sont utilisées pour entraîner les modèles,
— 20% sont réservées à l'évaluation.

Ce split n'est utilisé que dans un objectif d'évaluation et de comparaison des modèles, et non pour l'entraînement final, afin d'éviter toute fuite d'information vers le jeu de test.

L'optimisation des modèles est réalisée de manière **manuelle et itérative**. Plutôt que d'utiliser une recherche exhaustive de type *Grid Search*, trop coûteuse compte tenu du volume des données, les hyperparamètres sont ajustés progressivement en s'appuyant sur :

— les performances RMSE observées sur le jeu de validation,
— des tests ciblés sur un nombre limité de paramètres clés (profondeur des arbres, taux d'apprentissage, régularisation, pondération des modèles),
— la stabilité des prédictions et la cohérence des résultats.

Cette approche permet de trouver un compromis efficace entre performance, temps de calcul et simplicité de mise en œuvre.

5 Soumission 1 — Modélisation séparée FREQ / CM

5.1 Motivation et principe actuariel

La première stratégie adoptée repose sur une décomposition actuarielle classique, largement utilisée en assurance non-vie. L'idée est de modéliser séparément les deux composantes fondamentales du risque :

— la **fréquence** des sinistres,
— le **coût moyen** conditionnel à la survenance d'un sinistre.

Cette approche présente plusieurs avantages :

— elle est interprétable d'un point de vue métier,
— elle permet d'analyser séparément les facteurs influençant la probabilité de sinistre et ceux influençant sa sévérité,
— elle est conforme aux pratiques actuarielles traditionnelles.

La charge prédite est alors reconstruite par la relation :

$$\widehat{\texttt{CHARGE}} = \widehat{\texttt{FREQ}} \times \widehat{\texttt{CM}} \times \texttt{ANNEE_ASSURANCE}.$$

5.2 Choix des modèles

Deux modèles distincts sont entraînés.

Modélisation de la fréquence (`FREQ`). La variable `FREQ` est positive, fortement asymétrique et dominée par des valeurs proches de zéro. Un **RandomForestRegressor** est utilisé car :

— il est robuste aux outliers,
— il capture des interactions non linéaires complexes,
— il nécessite peu de réglages fins,
— il est stable sur de grands volumes de données.

Le paramètre `min_samples_leaf` est volontairement élevé afin de réduire la variance et d'éviter un sur-apprentissage local sur des segments peu représentés.

Modélisation du coût moyen (`CM`). La variable `CM` présente une distribution à queue lourde, typique des coûts de sinistres. Un **GradientBoostingRegressor** est choisi car :

— il optimise une fonction de perte de manière itérative,
— il permet de mieux modéliser les variations fines du coût,
— il est performant sur des problèmes de régression non linéaire.

Une profondeur limitée des arbres est imposée afin de favoriser la généralisation.

Listing 2 – Soumission 1 : Modélisation séparée FREQ / CM

```
rf_freq = RandomForestRegressor(
```

```
    n_estimators=200,
    min_samples_leaf=50,
    random_state=42,
    n_jobs=-1
)

gb_cm = GradientBoostingRegressor(
    n_estimators=200,
    learning_rate=0.05,
    max_depth=3,
    random_state=42
)
```

5.3 Protocole d'évaluation

Le protocole d'évaluation utilisé pour cette soumission s'inscrit dans le cadre méthodologique général présenté à la section précédente.

Un découpage interne **80/20** est appliqué au jeu d'apprentissage afin d'évaluer les performances du modèle avant soumission. Ce jeu de validation permet de comparer différentes configurations de modèles et de contrôler le sur-apprentissage.

Les prédictions sont contraintes à être positives par un *clipping*, afin d'éviter des valeurs négatives non plausibles et de garantir la stabilité numérique lors de la reconstruction de la variable cible.

5.4 Résultats obtenus

Sur le jeu de validation interne, la performance mesurée est :

$$\mathrm{RMSE}_{val}(\texttt{CHARGE}) \approx 7045.$$

Après réentraînement des modèles sur la totalité de l'échantillon d'apprentissage et soumission sur la plateforme, le score public obtenu est :

$$\mathrm{RMSE}_{public} = 5604.55.$$

Ce résultat valide la cohérence globale du pipeline et constitue une **baseline solide** pour les expérimentations ultérieures.

5.5 Analyse critique

Bien que performante, cette approche présente une limite structurelle importante. La charge est obtenue par la multiplication de deux prédictions indépendantes. D'un point de vue statistique, cela implique que :

— les erreurs relatives sur `FREQ` et `CM` se propagent,
— la variance globale de la prédiction est amplifiée,
— les instabilités sont particulièrement marquées lorsque `FREQ` est proche de zéro.

Ces limitations motivent l'exploration de stratégies alternatives plus directes.

6 Limites de la modélisation séparée

La variable `FREQ` est extrêmement déséquilibrée, avec une forte concentration de valeurs nulles ou quasi nulles. Dans ce contexte, une faible erreur absolue sur la fréquence peut induire une erreur relative importante sur le coût moyen reconstruit.

De plus, la multiplication de deux estimateurs bruités augmente mécaniquement la variance de la prédiction finale, ce qui limite les gains potentiels en RMSE. Ces observations conduisent naturellement à envisager une modélisation directe du *pure premium*, présentée dans les sections suivantes.

7 Soumission 2 — Modélisation du pure premium avec Tweedie

7.1 Motivation théorique

Plutôt que de prédire directement la charge totale associée à chaque observation, une première amélioration consiste à reformuler le problème de régression en introduisant une nouvelle variable cible représentant le coût annuel moyen attendu.

Cette variable est définie comme le rapport entre la charge totale observée et la durée d'exposition associée à chaque observation. Cette reformulation permet de ramener le problème à une régression sur une grandeur normalisée, indépendante de l'exposition, ce qui facilite l'apprentissage des modèles et améliore leur stabilité numérique.

La variable cible ainsi définie est notée :

$$\mathrm{PP} = \frac{\texttt{CHARGE}}{\texttt{ANNEE_ASSURANCE}}.$$

Elle correspond au coût annuel moyen attendu par observation. D'un point de vue pratique, cette formulation permet d'agréger en une seule quantité l'information liée à la fréquence d'occurrence et à la sévérité des événements, sans avoir à modéliser explicitement ces deux composantes de manière séparée.

L'analyse exploratoire des données montre que la distribution du pure premium présente plusieurs caractéristiques importantes :

— une proportion élevée de valeurs nulles,
— des valeurs strictement positives continues,
— une forte asymétrie accompagnée d'une queue lourde.

Ces propriétés rendent les hypothèses de normalité inadaptées et motivent le recours à des modèles capables de gérer simultanément la présence de zéros et des valeurs positives très dispersées.

7.2 Justification de la loi de Tweedie

La loi de Tweedie constitue une famille de distributions paramétrées par un coefficient de variance $p \in (1, 2)$, permettant de modéliser des variables aléatoires présentant à la fois une masse en zéro et une distribution continue positive.

D'un point de vue probabiliste, cette loi peut être interprétée comme un modèle composé, dans lequel la variable cible est la somme d'un nombre aléatoire de composantes positives :

$$Y = \sum_{k=1}^{N} Z_k, \quad N \sim \mathrm{Poisson}(\lambda), \quad Z_k \sim \mathrm{Gamma}(\alpha, \beta).$$

Cette formulation permet de capturer naturellement :

— la présence de nombreuses observations nulles,
— une dispersion importante des valeurs positives,
— une variance croissant avec la moyenne.

La loi de Tweedie est ainsi particulièrement adaptée à la modélisation de variables cibles continues, positives et fortement asymétriques, telles que le pure premium observé dans ce jeu de données.

7.3 Modèle utilisé : XGBoost Tweedie

Le modèle retenu est un **XGBoostRegressor** avec une fonction objectif basée sur la loi de Tweedie. Ce choix est motivé par :

— la capacité de XGBoost à capturer des relations non linéaires complexes,
— sa robustesse sur des jeux de données de grande dimension,
— l'intégration directe d'une fonction de perte adaptée à la distribution de la variable cible.

Une optimisation manuelle des hyperparamètres est réalisée afin de trouver un compromis satisfaisant entre biais et variance. Le modèle final retenu est présenté ci-dessous.

Listing 3 – Soumission 2 : XGBoost Tweedie pour le pure premium

```
xgb_tweedie = XGBRegressor(
    n_estimators=190,
    learning_rate=0.03,
    max_depth=3,
    min_child_weight=60,
    subsample=0.8,
    colsample_bytree=0.8,
    reg_lambda=20,
    objective="reg:tweedie",
    tweedie_variance_power=1.2,
    tree_method="hist",
    random_state=42
)
```

7.4 Modélisation complémentaire de la fréquence

Dans cette soumission, la fréquence est également estimée à l'aide d'un modèle **XGBoost Poisson**. Cette prédiction n'intervient pas directement dans l'optimisation de la charge totale, mais permet :

— de produire un fichier de soumission cohérent,
— de reconstruire un coût moyen implicite,
— de comparer différentes stratégies de modélisation.

Un seuil minimal est imposé sur la fréquence prédite afin d'éviter les instabilités numériques liées aux divisions par des valeurs proches de zéro.

Listing 4 – Soumission 2 : XGBoost Poisson pour Freq

```
xgb_freq = XGBRegressor(
    n_estimators=3000,
    learning_rate=0.05,
    max_depth=3,
    min_child_weight=50,
    subsample=0.8,
    colsample_bytree=0.8,
    reg_lambda=10.0,
    objective="count:poisson",
    tree_method="hist",
    random_state=42,
    n_jobs=-1
)
```

7.5 Résultats

Sur le jeu de validation interne, la performance obtenue est :

$$\mathrm{RMSE}_{val}(\texttt{CHARGE}) \approx 7037.73.$$

Ce résultat améliore la baseline issue de la modélisation séparée. Le gain reste modéré mais constant, traduisant une meilleure stabilité du modèle et une réduction de la variance globale.

7.6 Contrôles de cohérence et validation de la soumission

Avant la soumission finale sur la plateforme, plusieurs vérifications systématiques ont été réalisées afin de garantir la cohérence et la validité du fichier produit.

Le fichier de soumission contient exactement 95 852 observations, correspondant à l'ensemble du jeu de test, et respecte strictement le format attendu avec les cinq variables requises (`ID`, `FREQ`, `CM`, `ANNEE_ASSURANCE`, `CHARGE`).

Aucune valeur manquante n'est présente dans le fichier final, ce qui garantit l'absence d'erreurs de format lors de la soumission.

L'analyse statistique descriptive montre que :

— la fréquence prédite reste majoritairement faible, avec une médiane proche de zéro, en cohérence avec la distribution observée sur l'échantillon d'apprentissage ;

— le coût moyen et la charge présentent une forte dispersion, caractéristique de distributions asymétriques à queue lourde ;

— les valeurs extrêmes restent numériquement stables et limitées, sans explosion artificielle liée à la reconstruction de la charge.

Ces contrôles confirment que la modélisation du pure premium combinée à une estimation séparée de la fréquence produit des prédictions numériquement stables, cohérentes et directement exploitables dans le cadre du challenge.

7.7 Analyse biais–variance

La modélisation directe du pure premium à l'aide d'une loi de Tweedie réduit significativement la variance induite par la combinaison de plusieurs modèles indépendants.

En contrepartie, elle introduit un biais lié à l'hypothèse de distribution. Dans ce cas précis, le compromis biais–variance est favorable, ce qui explique l'amélioration observée sur la métrique RMSE.

8 Soumission 3 — Tweedie avec fréquence fixée

8.1 Motivation

L'analyse des résultats de la soumission 2 montre que la prédiction explicite de la fréquence n'apporte qu'un gain marginal, tout en introduisant une variabilité supplémentaire dans la reconstruction de la charge totale.

La soumission 3 adopte donc une stratégie volontairement plus simple :

— le pure premium est prédit à l'aide du modèle XGBoost Tweedie,

— la fréquence est fixée à une constante globale estimée sur l'ensemble d'apprentissage.

Cette approche permet de tester l'hypothèse selon laquelle la complexité supplémentaire apportée par un modèle dédié à la fréquence n'est pas nécessaire pour optimiser la métrique finale.

Listing 5 – Soumission 3 : fréquence fixée à la médiane

```
freq_ref = np.median(y_train["FREQ"].values)
freq_ref = max(freq_ref, 1e-3)

freq_test_pred = np.full(len(X_test), freq_ref)
```

8.2 Justification statistique

D'un point de vue théorique, l'estimateur constant égal à la médiane minimise l'erreur absolue moyenne, et constitue un estimateur robuste en présence de distributions très asymétriques.

Dans un cadre de minimisation de la RMSE, un estimateur simple peut ainsi présenter une meilleure capacité de généralisation qu'un modèle plus complexe, dont la variance domine les gains potentiels.

8.3 Interprétation

Fixer la fréquence revient à supposer que la variabilité principale de la variable cible est portée par le modèle de pure premium, et que l'hétérogénéité associée à la fréquence individuelle est difficilement apprenable à partir des variables disponibles.

Ce choix s'inscrit dans une logique classique en apprentissage statistique : lorsqu'un sous-modèle apporte peu d'information prédictive, le remplacer par une approximation simple permet souvent d'améliorer la stabilité globale du pipeline.

8.4 Résultats

La performance obtenue est comparable à celle de la soumission 2 :

$$\mathrm{RMSE}_{\text{Soumission 2}} = \mathrm{RMSE}_{\text{Soumission 3}} = 5601,55$$

Ce résultat indique que la modélisation Tweedie du pure premium capture déjà l'essentiel de l'information pertinente pour la prédiction de la charge totale.

8.5 Analyse biais–variance

La suppression de la modélisation explicite de la fréquence réduit la complexité globale du pipeline et limite la variance introduite par un sous-modèle dont le pouvoir prédictif est faible.

Empiriquement, cette simplification n'entraîne pas de dégradation de la performance mesurée en RMSE par rapport à la soumission 2. Cela suggère que l'information apportée par la prédiction explicite de la fréquence est redondante ou déjà capturée par le modèle de pure premium.

Dans ce contexte, l'utilisation d'un estimateur constant pour la fréquence constitue un compromis acceptable, permettant de conserver une performance équivalente tout en améliorant la robustesse et la stabilité du modèle.

9 Soumission 4 — Combinaison XGBoost et GLM (modèle final)

9.1 Motivation

Le cadre du data challenge définit explicitement un modèle de référence basé sur des régressions linéaires généralisées (GLM), utilisé comme benchmark officiel pour l'évaluation des performances.

Dans cette dernière soumission, l'objectif n'est donc pas de comparer directement XGBoost et GLM en tant que modèles concurrents, mais d'explorer dans quelle mesure l'intégration du modèle de référence au sein d'une approche plus flexible permet d'améliorer la robustesse des prédictions.

La soumission 4 s'inscrit ainsi dans une démarche de combinaison de modèles, visant à tirer parti :

- de la capacité de XGBoost à modéliser des relations non linéaires complexes,
- de la structure statistique et de l'effet de régularisation implicite du GLM utilisé dans le benchmark.

Cette approche permet d'évaluer si le modèle de référence apporte une information complémentaire lorsqu'il est combiné à un modèle de machine learning plus expressif.

9.2 Principe de la combinaison

Deux modèles sont entraînés pour prédire le pure premium :
— un **XGBoost Tweedie**, capturant les non-linéarités complexes,
— un **GLM Tweedie**, apportant une structure statistique robuste.

Les prédictions issues de ces deux modèles sont ensuite combinées au moyen d'un **blend linéaire** :

$$\widehat{PP} = w \cdot \widehat{PP}_{XGB} + (1 - w) \cdot \widehat{PP}_{GLM},$$

où le poids w est optimisé empiriquement sur le jeu de validation.

La fréquence est estimée séparément à l'aide d'un **GLM Poisson**, conformément à la méthodologie du benchmark officiel du challenge.

9.3 Implémentation

Listing 6 – Soumission 4 : Blend XGBoost Tweedie + GLM Tweedie

```
pp_xgb = xgb_final.predict(X_test_enc)
pp_glm = glm_final.predict(X_test_enc)

w = 0.9
pp_test = w * pp_xgb + (1 - w) * pp_glm
pp_test = np.clip(pp_test, 0, None)
```

La charge est ensuite reconstruite par :

$$\widehat{\texttt{CHARGE}} = \widehat{PP} \times \texttt{ANNEE_ASSURANCE}.$$

9.4 Résultats

Cette approche permet d'obtenir le meilleur score du projet :

$$\text{RMSE}_{public} = 5600.84.$$

Ce résultat améliore :
— le benchmark GLM fourni par le site,
— les approches purement basées sur des modèles de machine learning,
— les stratégies reposant sur une modélisation séparée des composantes.

9.5 Analyse finale

Le gain observé peut s'expliquer par :
— une réduction de la variance induite par le mécanisme de blending,
— la complémentarité entre un modèle flexible et un modèle plus contraint,
— l'ancrage sur le modèle de référence défini par le challenge.

Cette soumission constitue ainsi un compromis équilibré entre performance prédictive, stabilité numérique et respect du cadre méthodologique imposé.

10 Conclusion

Ce projet a permis d'explorer et de comparer plusieurs stratégies de modélisation pour la prédiction de la charge d'assurance incendie, dans un contexte de données volumineuses, hétérogènes et fortement asymétriques.

Dans un premier temps, la décomposition classique de la charge en fréquence et coût moyen s'est révélée pertinente d'un point de vue interprétatif. Toutefois, cette approche souffre d'une

instabilité statistique liée à la propagation multiplicative des erreurs, en particulier lorsque la fréquence est proche de zéro.

Dans un second temps, la modélisation directe du *pure premium* à l'aide d'une loi de Tweedie a permis de reformuler le problème sous une forme plus adaptée aux propriétés empiriques des données. Cette approche, combinée à un modèle de gradient boosting implémenté par **XGBoost**, s'est montrée plus robuste et plus stable numériquement, tout en améliorant la performance globale selon la métrique RMSE.

Enfin, l'intégration du modèle de référence basé sur les régressions linéaires généralisées (GLM) au sein d'un mécanisme de combinaison de modèles a permis d'exploiter la complémentarité entre approches statistiques classiques et méthodes de machine learning. Cette stratégie hybride s'est révélée être la plus performante du projet, en améliorant le benchmark officiel tout en respectant le cadre méthodologique imposé par le challenge.

Au-delà des résultats obtenus, ce travail met en évidence l'intérêt des approches hybrides en data science appliquée, où la combinaison de modèles simples et interprétables avec des modèles plus flexibles permet d'atteindre un compromis efficace entre performance prédictive, stabilité et robustesse.